


NAMA: SUKMA BAGUS WAHASDWIKA

NIM : 2241720223 KELAS : TI - 3D


## BIG DATA - 09 Spark SQL

# Siapkan lingkungan Spark Cluster





### Praktikum: Membangun ETL Pipeline

1. Extract: Baca data dari file CSV (sales\_data.csv).



- 2. Transform:
  - Filter transaksi dengan Revenue > \$100.
  - Hitung total penjualan per kategori.
- 3. Load: Simpan hasil ke Parquet. (Hasil Praktikum di bawah ini)





## BIG DATA - 09 Spark SQL

#### Analisis Data Retail

#### **Dataset**

• **Format**: CSV (sales\_data.csv)

```
∷ sales_data.csv yesterday
```

### **Tugas**

1. Hitung total pendapatan per bulan.

```
ANALISIS DATA RETAIL Dataset
      · Format: CSV (sales data.csv)
      Tugas 1. Hitung total pendapatan per bulan. 2. Identifikasi 5 produk terlaris. 3. Simpan hasil dalam format Parquet.
[3]: # Solusi 1 : Pendapatan perbulan
      from pyspark.sql import SparkSession
from pyspark.sql.functions import month, sum, count
      spark = SparkSession.builder.appName("ETLPipeline").getOrCreate()
      df = spark.read.csv("sales_data.csv", header=True, inferSchema=True)
      df_revenue = df.withColumn("month", month("Date")) \
                       .agg(sum(df["Unit_Price"] * df["Order_Quantity"]).alias("total_revenue"))
      |month|total revenue|
                  10158080
          12
                   7832338
10085537
                    8201790
9859851
                    6517880
                    6348349
          10
                    6709394
                    7608734
           2
```

2. Identifikasi 5 produk terlaris.



NAMA: SUKMA BAGUS WAHASDWIKA

NIM : 2241720223 KELAS : TI - 3D

### BIG DATA - 09 Spark SQL

3. Simpan hasil dalam format Parquet.



#### Evaluasi

#### **Soal Latihan**


1. Baca data dari table di database MySQL anda menggunakan Spark,


DB: framefit

Tabel: kacamata



- Konfigurasi JDBC, download file mysql-connector-j-9.3.0.jar. Kemudian file mysql-connector-j-9.3.0.jar di copy ke spark-notebook dengan perintah docker cp mysql-connector-j-9.3.0.jar beautiful\_bassi:/usr/share/java/.
- Dilanjutkan dengan menjalankan kode progam seperti dibawah





# BIG DATA - 09 Spark SQL

2. Buat query Spark SQL untuk menghitung Jumlah row dalam table tersebut

```
df.createOrReplaceTempView("kacamata")
jumlah_row = spark.sql("SELECT COUNT(*) AS jumlah_row FROM kacamata").show()

+-----+
|jumlah_row|
+-----+
| 62|
+-----+
```

# Kesimpulan

- Spark SQL menyediakan antarmuka terstruktur untuk pemrosesan data besar.
- DataFrame & Dataset APIs memungkinkan manipulasi data dengan sintaks mirip SQL.
- DataSources API mendukung integrasi dengan berbagai format penyimpanan.